



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위논문

인공신경망을 이용한 자율주행 센서 데이터 융합
방법 연구

A Study on Sensor Data Fusion using Neural
Networks for Autonomous Driving Applications

운 봉 영

한양대학교 대학원

2017 년 2 월

석사학위논문

인공신경망을 이용한 자율주행 센서 데이터 융합
방법 연구

A Study on Sensor Data Fusion using Neural
Networks for Autonomous Driving Applications

지도교수 이 상 선

이 논문을 공학 석사학위논문으로 제출합니다.

2017 년 2 월

한양대학교 대학원

전자컴퓨터통신공학과

운 봉 영

이 논문을 윤봉영의 석사학위 논문으로 인준함

2017 년 2 월

심 사 위 원 장 : 윤 동 원
심 사 위 원 : 이 상 선
심 사 위 원 : 김 선 우



한양대학교 대학원

국문요지

현재 자율주행 자동차는 빠르게 발전하고 있다. 빠른 미래에 매우 핵심적인 역할을 할 것으로 예상되어 많은 국가 및 기업, 연구소에 관계없이 모두 집중하고 있다. 자율주행 자동차에는 주변 인식(Perception), 측위(Localization), 경로 예측(Path Planning), 차량 제어(Vehicle Control) 이렇게 4가지 요소가 필수적이다. 그 중 주변 인식에서는 Lidar, Radar, Vision, Ultrasonography 등 다양한 센서를 차량에 장착하여 주변 환경에 대한 정보와 자차 주변에 있는 객체(자동차, 오토바이, 자전거, 사람 등)의 정보를 얻게 된다. 자율 주행을 위해서는 주변환경에 대한 정확한 인식이 되어야 충돌을 방지하고 가감속 등의 차량 제어를 할 수 있기 때문이다.

본 논문에서는 그 중 필수적으로 사용되는 Lidar, Radar, Vision 센서의 데이터를 인공지능망(Neural Network)을 통하여 융합하고, 각 센서를 단일로 사용하는 것보다 좋은 성능을 나타내는 것을 증명한다. 이 전의 연구들은 두 가지 이상의 센서를 융합하는데 칼만 필터를 많이 사용하였으나, 이는 알고리즘의 복잡성을 갖게 되고 환경에 따라 변수를 추가하는 등의 작업이 필요한 단점을 가지고 있다. 또한 센서 데이터는 보통 상대 객체의 외곽에 대한 거리를 주기 때문에 정확한 차량 위치를 얻기 위하여 이를 보상해주어야 하는 단점도 존재한다. 반대로 인공지능망은 학습을 통하여 보상의 개념이 필요하지 않게 된다. 본 실험에서는 일반적인 주행 환경에서의 직진, 좌회전, 우회전 등의 기본적인 상황을 각 센서를 개별로 사용하였을 때와 융합하였을 때를 비교하여 성능을 평가하였다. 먼저 직진구간에서 차량이 직진주행을 하였을 때, 각 센서를 개별로 사용하였을 때 Lidar는 0.4815m, Radar는 0.6066m, Vision은 2.2120m의 RMS 전체적으로 낮은 오차를 갖는 모습을 확인 하였지만, Vision

의 경우 직진 주행이지만 거리가 멀어지면서 발생하는 오차가 매우 크게 나타남을 알 수 있었다. 그리고 센서 데이터를 융합하였을 시, 0.2020m의 가장 낮은 RMS로 개별 센서에서 가장 낮은 RMS를 갖는 Lidar보다 좋은 성능을 나타내는 것을 확인 할 수 있었다. 다음으로 직진구간에서 차선변경이 있는 경우에는 전체적으로 앞서 직진 주행보다 큰 RMS를 갖는 것을 확인 할 수 있었으며, Lidar의 경우에는 0.4932m, Radar는 0.6379m, Vision은 2.7435m의 RMS를 나타내었다. 3개의 센서 모두 차선이 변경하는 곳에서 순간적으로 큰 오차가 발생하였다. 센서 데이터를 융합한 경우에도 0.3138m 로 가장 낮은 RMS를 보였지만 직진주행보다는 조금 높은 RMS를 갖는 것을 확인하였다.



목 차

| | |
|--------------------------------------|-----|
| 국문요지 | i |
| 목차 | iii |
| 그림 목차 | v |
| 표 목차 | vi |
| | |
| 제1장 서론 | 1 |
| 제1.1절 연구 배경 | 1 |
| 제1.2절 연구 필요성 및 목적 | 3 |
| 제1.3절 논문 구성 | 6 |
| | |
| 제2장 차량 융합센서 시스템 설계 | 6 |
| 제2.1절 Lidar 기반 객체인식 기술 | 6 |
| 제2.2절 Radar 기반 객체인식 기술 | 10 |
| 제2.3절 Vision 기반 객체인식 기술 | 12 |
| 제2.4절 시뮬레이션에 적용한 요소기술 및 시스템 구성 | 14 |
| | |
| 제3장 센서데이터 융합을 위한 인공지능망 구축 | 17 |
| 제3.1절 인공지능망 원리 | 17 |
| 제3.2절 제안 시스템에서의 신경망 구성 방법 | 22 |
| 제3.3절 객체인식 오차 보정 알고리즘 | 27 |
| | |
| 제4장 실험 및 결과 | 29 |
| 제4.1절 실험 환경 | 29 |
| 제4.2절 실험 시나리오 | 30 |
| 제4.3절 실험 결과 및 분석 | 33 |
| 4.3.1 직진구간 직진실험 | 33 |
| 4.3.2 직진구간 차선변경 실험 | 37 |
| 4.3.3 교차로 반대 차선 우회전 실험 | 41 |
| 4.3.4 교차로 좌회전 실험 | 45 |
| | |
| 제5장 결론 | 49 |
| | |
| 참고문헌 | 52 |

| | |
|----------------|----|
| ABSTRACT | 56 |
|----------------|----|



그림 목차

| | | |
|---------|--|----|
| 그림 1.1 | 자율주행을 위한 4대 요소 | 1 |
| 그림 1.2 | ADAS 시장 전망 | 3 |
| 그림 2.1 | Lidar 시스템 기본 구성 및 동작원리 | 7 |
| 그림 3.1 | 신경세포의 구성 | 18 |
| 그림 3.2 | 인공 신경망 | 18 |
| 그림 3.3 | 맥클로크-피츠 뉴런 | 18 |
| 그림 3.4 | 활성화 함수 | 19 |
| 그림 3.5 | 신경망 층에 따른 결정 영역 | 20 |
| 그림 3.6 | 역전파 알고리즘 구조 | 21 |
| 그림 3.7 | 실험에 사용할 Neural Network 알고리즘 | 23 |
| 그림 3.8 | 각 구간에서의 Training 과정 | 24 |
| 그림 3.9 | Training data 개수에 따른 RMS 비교 | 26 |
| 그림 3.10 | 객체인식 오차 보정 알고리즘 | 27 |
| 그림 4.1 | 실험 시나리오 | 32 |
| 그림 4.2 | 직진구간 직진주행 시 각 센서 및 Fusion error 비교 | 36 |
| 그림 4.3 | 직진구간 차선 변경 시 각 센서 및 Fusion error 비교 | 40 |
| 그림 4.4 | 교차로 반대 차선 우회전 시 각 센서 및 Fusion error 비교 | 44 |
| 그림 4.5 | 교차로 좌회전 시 각 센서 및 Fusion error 비교 | 48 |

표 목차

| | | |
|-------|--|----|
| 표 1.1 | 업체별 자율주행차 상용화 계획 | 2 |
| 표 2.1 | Lidar 기술 종류 | 8 |
| 표 2.2 | 2D/3D Laser Scanner 주요 제품 및 규격 | 9 |
| 표 2.3 | Radar 종류에 따른 규격 | 11 |
| 표 2.4 | 비전을 이용한 기술 | 12 |
| 표 2.5 | 대표적인 Stereo Vision 규격 | 13 |
| 표 2.6 | 각 센서 위치 및 규격 | 15 |
| 표 2.7 | PreScan에서 제공하는 Lidar, Radar, Vision 센서 데이터 | 16 |
| 표 3.1 | Neural Network Layer수와 node수에 따른 RMS 비교 | 22 |
| 표 4.1 | 직진 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크 | 34 |
| 표 4.2 | 차선 변경 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크 | 38 |
| 표 4.3 | 교차로 우회전 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크 | 42 |
| 표 4.4 | 교차로 좌회전 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크 | 46 |



제1장 서론

제1.1절 연구배경

최근 자율주행에 대한 관심이 급증하였다[1,2]. 구글은 도요타 차량을 개조하여 무인 주행 자동차를 개발하여 시험 주행을 해 왔다[3]. 2009년 구글카가 본격적으로 시험운행을 시작하면서 자동차 업계들의 자율주행 연구를 앞당기게 되었다. 자율주행 자동차를 위해서는 그림 1.1과 같이 주변 인식(Perception), 측위(Localization), 경로 예측(Path Planning), 차량 제어(Vehicle Control) 이렇게 4가지 요소가 필수적이다. 인식은 Lidar, Radar, Vision 등의 센서를 이용하여 정적장애물 혹은 차량, 보행자 등의 동적 장애물과 도로표식 등을 검지하는 것이고, 측위는 GPS, INS 등을 이용하여 자차의 절대위치 또는 상대 위치를 검지하는 것이다. 경로 예측은 위 정보들을 토대로 상대 객체가 앞으로 어떠한 방향, 속도, 경로로 이동할 지를 예측하는 과정이며, 제어는 자차의 주어진 경로를 나아가기 위한 조향, 가감속 혹은 다른 객체와의 충돌 및 긴급 상황을 피하기 위한 조정을 말한다[4,5].




그림 1.1 자율주행을 위한 4대 요소

이에 따라 현재 많은 자동차 회사들이 연구를 진행 중이다. 대표적으로 BMW는 인텔, 모빌아이와 협력하여 2021년 자율주행 전기 자동차 출시를 목표로 하고 있고, 테슬라는 비전 센서를 장착하여 자율주행 기술은 연구하고 있다. 비록 지난 5월 사고가 발생하였지만 이를 개선하여 인간이 운전하는 것보다 10배 안전한 자율주행 차량을 개발하겠다는 목표를 세웠다. 마지막으로 현대자동차는 현재 제네시스 차량에 자율주행 레벨 2단계 수준의 성능을 구현하였고, 2020년 자율주행 레벨 4단계로 일반도로용 자율주행차 시판을 목표로 하고 있다. 다음 표 1.1에는 업체별 자율주행차 상용화 계획이 나타나있다[2].

표 1.1 업체별 자율주행차 상용화 계획

| 업체 | 상용화 예정 시기 |
|------|--|
| 현대차 | 2016년까지 레벨 2단계 고속도로용 자율주행차 시판 2020년까지 레벨 4단계 일반도로용 자율주행차 시판 |
| 아우디 | 2020년까지 레벨 4단계 개발 |
| 폭스바겐 | 2020년까지 레벨 4단계 개발 |
| GM | 2016년까지 레벨 3단계 개발 |
| 벤츠 | 2020년까지 레벨 4단계 개발 |
| 구글 | 2017년까지 레벨 4단계 개발 |
| 르노 | 2016년까지 레벨 2단계 개발 2020년까지 레벨 4단계 개발 |
| 닛산 | 2020년까지 레벨 4단계 개발 |
| 토요타 | 2016년까지 레벨 3단계 개발 |
| 볼보 | 2017년까지 레벨 3단계 개발 |

자율주행 자동차가 되기 위한 주요 기술로 ADAS(Advanced Driver Assistance System)이 있다. Vision, Radar, Lidar 등의 센서를 이용하여 주변 환경 및 객체의 정보를 획득하고 차량을 제어 하는 기술이다. 대표적 기술로는 LDW(Lane Departure Warning), FCW(Forward Collision Warning),

LKA(Lane Keeping Assistant) 등이 있다[6]. 따라서 ADAS 시장도 매우 빠르게 성장할 것으로 예측하고 있다. 그림 1.2와 그림 1.3에서 확인 할 수 있듯이 Unit base로 2013년부터 2020년 까지 연 평균 15%, Sale base로 2012년부터 2020년까지 연 평균 41% 성장할 것으로 예측되고 있다[7].

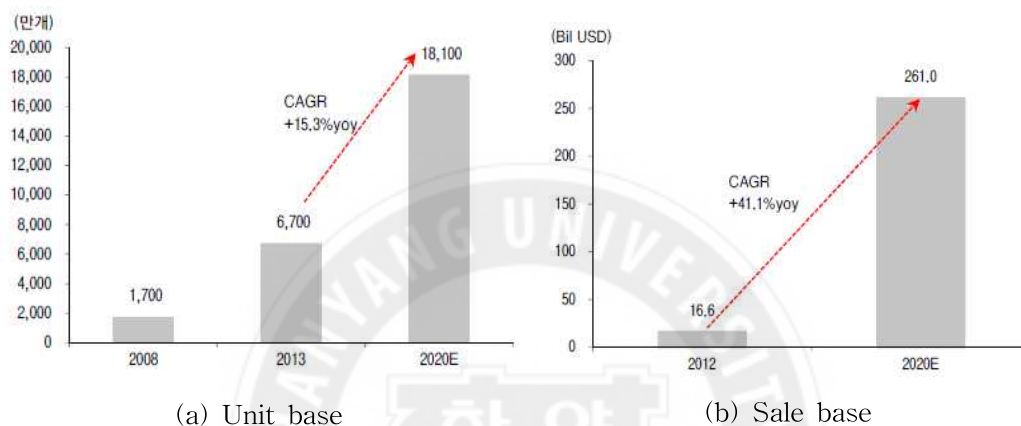


그림 1.2 ADAS 시장 전망

제1.2절 연구의 필요성 및 목적

자율주행을 위한 센서 연구는 꾸준히 진행 되어 오고 있다. 과거 센서 개별적인 연구에서 최근 융합한 연구로 진행되어 가고 있다. 먼저 Lidar 센서는 과거부터 높은 거리 정확도를 이용한 연구가 활발하였다. 2004년 Lidar를 통하여 다중 객체를 인식하고 추적하는 방법이 연구 되었으며[8], 2006년 H. Zhao는 “Joint tracking and classification of moving objects at intersection using a single-row laser range scanner”에서 교차로에서 움직이는 객체를 분류하고 추적하는 연구를 위하여 Lidar를 교차로에 설치하고, 객체의 움직임에 대한 Lidar 데이터를 Markov Chain방법을 적용하여 실험하였다[9]. 또한

2D Lidar 데이터를 처리에 Monte Carlo Localization 이론을 적용하여 3D 도시 환경에서 정확한 위치를 측정하는 연구도 진행 되었다[10]. 최근에는 Lidar가 객체 측정 시 감지 단계에서 객체 정보가 공간적으로 분산되는 특수성을 해결하기 위하여 감지 단계 없이 원시 데이터 처리를 사용하여 다중 객체 추적의 성능을 향상 시켰다[11]. 또한, ring compression analysis을 적용하여 객체가 Lidar의 폐색지역에 있어도 감지할 수 있는 방법을 연구하였다[12]. 그리고 Track-Before-Detect 방법을 적용하여 낮은 SNR의 객체도 감지 할 수 있는 연구도 하였다[13]. 이처럼 Lidar는 더 정밀하고 세밀한 객체 감지 및 추적을 위한 방향으로 연구 되고 있다.

Vision 센서는 이미지 형태의 정보를 알 수 있기 때문에 객체 인식 및 구분에 관한 연구들이 진행 되어왔다. U. Franke는 도심지에서 공이나 아이들과 같이 갑자기 나타나는 객체를 빠르게 감지할 수 있는 연구를 진행하였고[14], Yingping Huang은 3D 스테레오 카메라의 매칭 과정에 높은 계산 비용이 발생하는 것을 감소시키기 위하여 Edge 매칭 방법을 적용하여 근거리의 물체를 인식하는 방법을 제안하였다[15]. 근래에는 HMM(Hidden Markov Model)을 이용하여 차량의 특징을 찾아내고 이미지 평면에서 선행 차량의 위치 및 모션을 모델링하여 환경 및 조도 변화에 효과적으로 대처할 수 있는 연구를 진행 하였다[16]. 그리고 최근에는 객체 인식 시 Vision의 각 cell 마다 Histogram을 만들어 객체를 구분하는 HOG(Histogram of Oriented Gradient)방법과 주로 영상 질감에 이용되는 Gabor feature방법을 사용하여 차량 뿐만 아니라 도로 표식이나 표지판도 검출하는 연구를 진행하였다[17].

Radar 센서 같은 경우 종방향에 대한 정확성이 있지만 작은 FOV에 의하여 Vision과 함께 사용하여 연구 되어 왔다. 앞서 도로에서 Radar가 객체를 감지할 때, 가드레일과 차량의 구분을 두기 위한 방법으로 이미지 데이터를 함께 사용하여 차량 감지의 정확도를 높인 연구를 진행하였고[18], Vision 센서의

윤곽 기반 이미지 처리 방법을 적용하여 Radar가 감지한 객체의 정확도를 높이는 연구도 진행하였다[19]. 근래에는 상용 센서들이 자차를 추월하는 다른 차량에 대한 감지의 한계를 보완하기 위하여 Radar, Vision을 결합하였다. 주행 중 Vision에서 나타나는 진동으로 인한 오차나 조도 변경으로 인한 오차를 Radar를 이용하여 극복할 수 있도록 연구 하였다[20].

Lidar는 객체 추정 및 인식에 대해 높은 정확도를 가지고 있지만 그만큼 고가의 장비이다. Radar는 종방향에 대한 정확도를 높지만 작은 FOV나 객체 분류에 한계를 가지고 있어 단독으로 사용하는 것은 한계가 있다. 또한, Vision은 객체 분류에는 뛰어나나 영상 처리 속도와 거리에 따른 오차가 좋지 않다. 최근에도 Lidar, Radar, Vision 모두를 결합하여 정확한 객체 감지 및 객체 분류를 위한 연구가 진행 되고 있지만[21], 고가의 장비로 인하여 모두를 사용하는 연구는 아직 기업, 전문 연구소 위주이다.

본 논문에서는 Lidar, Radar, Vision을 개별적으로 사용한 센서 데이터와 이를 인공 신경망을 통하여 융합하여 각 센서들이 갖는 인식 거리의 한계, FOV 한계 등을 해결하고자 한다. 또한, 현재 센서 융합은 대부분 칼만필터를 통하여 연구 되는 것이 많은데[22], 이는 알고리즘의 복잡성과 환경 변화에 따른 변수 추가 등으로 인한 추가적 알고리즘 구현 등의 단점을 인공신경망으로 융합함으로써 알고리즘을 획일화시키기 위한 목적을 가지고 있다.

제1.3절 논문 구성

본 논문은 다음과 같이 구성되어 있다. 제 2장에서는 실험에서 사용될 센서에 대한 요소기술의 원리 및 주요 제품의 규격에 대하여 설명하고, 주요 제품과 추가적인 문헌들을 참고하여 시뮬레이션에서 어떠한 요소기술을 사용하고 시스템을 구성할지에 대하여 설명하였다. 제 3장에서는 2장에서 설명한 센서들의 데이터를 처리하기 위한 인공지능망에 대한 소개를 한다. 또한, 본 논문에서 사용하게 될 네트워크를 찾는 방법과 사전 학습의 방법에 대하여 제시하고, 마지막으로 객체인식시 발생하는 오차를 보정 할 수 있는 알고리즘에 대하여 설명한다. 제 4장에서는 2,3장에서 제시한 요소기술 및 시스템의 구성과 최적화된 네트워크를 기반으로 실험하며, 각 시나리오에 대한 설명 및 결과 분석으로 구성하여 제안된 기술의 성능평가를 한다. 4장에서는 실험 결과를 통하여 앞장에서 설명한 필터의 단점인 알고리즘의 복잡성을 해결할 수 있는지와 각 센서를 개별적으로 사용하였을 때와 융합하였을 때 각 센서의 단점을 보완하여 우수한 성능을 갖는지를 분석한다. 마지막으로 제5장에서는 본 연구에 대한 결론 및 향후 연구방향에 대하여 기술한다.

제2장 차량 융합센서 시스템 설계

본 장에서는 시뮬레이터에서의 시스템 구성을 위한 각 센서들의 요소기술 및 원리 그리고 각 센서들의 장단점을 설명하며, 실제 많이 사용 되고 있는 주요제품 스펙에 관하여 서술한다. 또한, 주요 제품 스펙 및 추가적인 문헌들을 참고하여 시뮬레이션에서 사용 될 규격과 장착 위치를 제시한다.

제2.1절 Lidar 기반 객체인식 기술

라이다 센서는 레이저를 목표물에 비춰 사물까지 거리, 방향, 속도 등을 감지할 수 있는 센서이다. 일반적으로 높은 에너지 밀도, 짧은 주기를 가지는 펄스 신호를 생성할 수 있는 레이저의 장점을 활용하여 정밀한 물성 관측 및 거리 측정에 활용 된다. 라이다는 그림 2.1과 같이 레이저 송신부, 레이저 검출부, 신호 수집 및 처리와 데이터를 송수신하기 위한 부분으로 구분된다[23].




그림 2.1 Lidar 시스템 기본 구성 및 동작원리

레이저 신호의 변조 방법에 따라 ToF(Time of Flight)방식과 PS(Phase

Shift) 방식으로 구분되며, 앞의 방식은 방사된 레이저 펄스신호가 측정 범위 내의 물체로부터 수신기에 반사되는 시간을 측정함으로써 거리를 측정하는 원리이다. 후자는 특정 주파수로 연속적으로 변조되는 레이저 빔을 방사하고 측정 범위 내에 있는 물체로부터 반사 되는 신호의 위상 변화량을 측정하여 시간 및 거리를 계산하는 원리이다[24]. 또한, Lidar는 어떠한 방식을 이용하나에 따라 표 2.1와 같이 다양한 기술이 존재하고 있다[23].

표 2.1 Lidar 기술 종류

| 기술 | 내용 |
|--------------------------------------|---|
| Elastic-backscatter LiDAR | 입자들의 운동량에 따라 후방 산란되는 빛의 스펙트럼 확장 특성을 이용 |
| Raman LiDAR | 분자 에너지 상태에 따라 분산되는 레이저 빛의 주파수 변화 및 Raman band 내의 세기 분포 분석을 이용 |
| Differential-absorption LiDAR (DIAL) | 파장이 다른 레이저 빔들의 측정 대상 물질의 흡수 차이를 이용 |
| Doppler LiDAR | Doppler 효과에 의해 발생하는 미세한 주파수 변화를 측정 |
| Laser Rangefinder | 물체로부터 반사되는 빔의 수신 시간을 이용하여 거리 측정 |
| Imaging LiDAR | 레이저 빔의 진행 방향에 대한 거리 정보를 포함, 공간에 대한 영상 모델링 가능한 기술 |

이러한 기술들을 이용한 실제 Lidar 센서 중 대표적인 제품을 다음 표 2.2에 설명하였다[24]. 자율 주행을 위해서 Lidar는 현재 2D laser scanner와 3D laser scanner를 사용하고 있는데 2D laser scanner는 회전 방식을 이용하여

레이저 빔의 진행 방향을 포함하는 특정 평면에서의 영상 정보를 수집한다. 하지만 3D 영상 구현을 위해서는 보다 빠른 데이터 수집이 필요하기에 한계가 존재한다. 3D laser scanner 같은 경우 광 시야각을 확보하는데 유리하지만 수직 방향의 해상도가 낮고 소형화하는데 어려움이 존재한다. Lidar 같은 경우 주변 객체에 대하여 빠르게 스캔하면서 상대거리, 상대속도를 정확하게 알 수 있다. 최근에는 도심지 환경에서 다중 객체를 정확하게 감지 할 수 있는 연구를 진행하였고[10], 낮은 SNR을 갖는 객체도 인지하는 높은 정확도에 대한 연구가 이루어지기도 하였다[13]. 하지만 Lidar는 다른 센서들에 비하여 인식거리가 짧은 편이어서 한정 적인 정보 습득만 가능하고, 고비용으로 일반적인 사용에 한정적이다.

표 2.2 2D/3D Laser Scanner 주요 제품 및 규격

| | unit | Velodyne (HDL-64) | SICK (LD-MRS) | Ibeo (LUX 8L) | Hokuyo (UTM-30L X/LN) |
|------------------|--------|----------------------|-------------------------------|------------------|-----------------------------|
| Laser wavelength | nm | 905 | 905 | 905 | 905 |
| Operating range | m | 120 | 0.5~250 | 200 | 0.1~60 |
| Horizontal FOV | degree | 360 | 85 w/4 layer 110 w/2 layer | 50 to - 60 | 270 |
| Vertical FOV | degree | +2 to - 24.8 | 3.2 | 6.4 | - |

제2.2절 Radar 기반 객체인식 기술

Radar(Radio Detection And Ranging)는 물체 위치, 방향을 측정하여 거리와 속도로 나타내어 준다. 거리 및 속도 측정은 도플러 효과에 의한 주파수 편이 측정을 통하여 하고 아래의 식에 따라 값을 계산한다.

$$\text{상대 거리 } R = \frac{c \times \Delta t}{2}, \quad \text{상대 속도 } v = \frac{\lambda \times f_d}{\cos \theta}$$

c 는 전파속도, f_d 는 도플러 주파수 편이, θ 는 센서와 객체간의 이루는 각도로 레이더 측정방향과 객체의 이동방향이 이루는 각도이다[25]. 다음과 같은 원리를 이용한 대표적인 Radar 기술은 다음과 같다[26].

MF-CW 레이더

1990년대 후반에 개발하였고, 주파수 연속변조파를 활용한다. 도플러를 이용한 레이더 경우 단일 정현파만으로는 거리 측정이 불가하여 반복적으로 주파수 변조를 한 후 거리 측정을 하도록 설계하였다. 이 때 변조 주파수를 낮게 하고 대역폭을 넓혀 거리 구분을 작게 두면 펄스 레이더보다 뛰어난 초 근거리, 고 정밀도 측정이 가능하다.

CW/FM-CW 레이더

2000년대 초반에 개발된 FM-CW(Frequency Modulation-CW) 레이더는 MF-CW 레이더가 가진 긴 자료처리 시간과 제로-도플러(Zero-Doppler)물체 및 정지 물체의 추적과 사거리 측정이 불가능한 단점을 보완하기 위하여 개발하였다.

데브리스(Debris) 레이더

2000년대 초반 개발된 데브리스 레이더는 다중추적레이더로 CW/FM-CW, CW/MF-CW 방식을 사용하여 빔 폭 내에서 이동하는 여러 표적신호를 동시에 감지하고 추적하기 위한 용도로 개발하였다.

이러한 기술들을 이용한 실제 Radar 센서를 종류에 따라 다음 표 2.3에 설명하였다[27]. Radar 같은 경우 거리에 따라 LRR(Long Range Radar), MRR(Middle Range Radar), SRR(Short Range Radar)로 나눌 수 있다. Radar는 다른 센서에 비하여 종방향에 대한 인식범위가 길고 또한 거리가 멀어 질수록 발생하는 오차도 적은 편이다. 하지만 FOV가 매우 좁은 편이기 때문에 객체 인식에 한계를 보인다. 또한 대부분의 Radar가 객체인식을 포인트 형태로 하기 때문에 상대거리, 상대속도 외에 어떠한 객체인지를 인식하는데 어려움이 있다. 따라서 Radar 단독으로 사용하기 보단 Vision 센서와 결합하여 객체 검지의 정확도를 높이는 연구가 주로 진행 되었다[18,19].

표 2.3 Radar 종류에 따른 규격

| | LRR | MRR | SRR |
|------------------|---------|---------|----------|
| Carrier Freq. | 77GHz | 79GHz | 79GHz |
| Range | 10-250m | 1m-100m | 0.15-30m |
| FOV | 15° | 40° | 80° |
| Range accuracy | 0.5m | 0.5m | 0.1m |
| Angular accuracy | 0.1° | 0.5° | 1° |

제2.3절 Vision 기반 객체인식 기술

비전 센서는 주변 환경이나 객체를 이미지 형태의 정보로 제공하는 센서이다. 비전 센서는 CCD(Charged Coupled Device)와 CMOS(Complementary Metal-Oxide Semiconductor) 방식으로 나눌 수 있는데 CCD는 MOS(Metal Oxide Silicon) 캐패시터가 서로 매우 근접한 위치에 있어 전하 캐리어가 캐패시터에 저장되고 이송되는 방식이고, CMOS는 제어회로 및 신호처리회로를 주변회로로 사용하는 기술을 이용하여 pixel 수만큼 MOS 트랜지스터를 만들고 이것을 이용하여 순차적인 출력을 검출하는 스위칭 방식이다.

비전 센서는 CCD, CMOS 기반으로 스테레오, 단안비전 등 다양하게 발전되어 자율주행에 이용되고 있다. 비전을 이용한 기술은 다음 표 2.4에 설명되어 있다[28].

표 2.4 비전을 이용한 기술

| 기술 | 내용 |
|--|--|
| Stereo Matching | 세로 edge를 통하여 매칭하는 단순 방법에서 영상 전체를 매칭하여 사용하는 방법으로 발전되어 가고 있음 |
| General Obstacle Detection(GOD) | 일반 적인 장애물을 검출하는 방식으로 물체의 유형과 상관없이 거리 정보를 기반으로 장애물을 인식 |
| Classifier-based Object Detection(COD) | 객체 외형의 학습시켜 만든 Classifier를 이용하여 영상에서 차량, 보행자 등을 검출하는 방식 |

이러한 기술들을 이용한 실제 자율주행에 사용하는 대표적인 Vision 센서 스펙을 다음 표 2.5에 설명하였다[29]. Vision 센서는 이미지 형태의 데이터를

제공하기 때문에 객체 구분에 확실히 뛰어나다. 또한 횡방향에 대한 오차도 매우 적은 편이다. 최근 Vision의 연산 비용으로 Edge 매칭 방법을 통하여 해결하려는 연구와[16] 도로 표식과 표지판 검출에도 높은 정확도를 보이기 위한 연구를 진행하였다[17]. 하지만 이미지 데이터는 Pixel 단위로 제공되기 때문에 거리가 멀어질수록 한 Pixel에 담는 정보량이 많아지면서 정확도가 낮아진다. 따라서 거리에 관하여 오차가 매우 큰 편이고, 종방향에 대한 정확도도 다른 센서에 비하여 낮은 편이다.

표 2.5 대표적인 Stereo Vision 규격

| | |
|-------------------|-------------|
| | 규격 |
| Range | 55m |
| Horizontal FOV | 80° |
| Vertical FOV | 29° |
| Matching accuracy | 0.25px |
| Measurement error | 0.01m at 5m |
| | 1.9m at 55m |

제2.4절 시뮬레이션에 적용한 요소기술 및 시스템 구성

본 실험에서는 시뮬레이션을 위하여 PreScan을 사용하였고 인공 신경망을 적용하기 위하여 Matlab을 사용하였다. 실험에 사용하게 될 차량은 전방에 2D Lidar 1대, LRR(Long Range Radar) 1대, 양 측방에 MRR(Middle Range Radar) 1대씩 총 2대 그리고 차량 앞 유리 부근에 Vision 1대로 총 5개의 센서로 구성되어있다. 센서 스펙은 앞 절에서 설명한 각 센서들의 원리와 대표적인 기술 및 주요 제품들과 여러 자료들을 참고하여 표 2.6과 같이 설정하였다 [29-34].



표 2.6 각 센서 위치 및 규격

| 센서 | Location | 규격 |
|--------|---|---|
| Lidar | X = 3.916m Y = 0 Z = 0.420m | Maximum range 80m Range accuracy 0.035 m Range resolution 0.01 m Angular accuracy 0.01 deg Angular resolution 0.25 deg Scanning angle 180 deg Laser wavelength 905 nm |
| LRR | X = 3.616m Y = 0m Z = 0.420m | Maximum range 200 m Range accuracy 0.1 m Angular accuracy 0.1 deg Angular resolution 0.25 deg Horizontal FOV 30 deg Frequency band 77 Hz |
| MRR | X = 3.916m Y = ± 0.8 m Z = 0.420m | Maximum range 100 Range accuracy 0.1 m Range resolution 0.5 m Angular accuracy 0.5 deg Horizontal FOV 80 deg (MRR) Frequency band 77 Hz |
| Vision | X = 1.90m Y = 0 Z = 1.40m | Maximum range 70 m (detection), 100 m (tracking) Horizontal FOV 47 deg Frame size 640x480 pixels Range accuracy 5% error at 44 m assuming 1 pixel error. |

그리고 실험에서 사용할 입력 값과 출력 값에 대해서는 표 2.7에 나타나 있듯이 PreScan서 제공하는 데이터 중 상대 객체의 x,y,z 좌표, 각 센서의 Range, Theta 값을 이용한다. 상대 객체의 GPS 좌표는 목표 값으로 이용하며 각 센서의 Range, Theta 데이터는 목표 값을 찾기 위한 입력 값으로 사용한다.

표 2.7 PreScan에서 제공하는 Lidar, Radar, Vision 센서 데이터

| Lidar, Radar | Vision |
|-------------------------------------|-------------------------------------|
| ActiveBeamID | Object ID[-] |
| Range[m] | ObjectTypeID[-] |
| DopplerVelocity[ms ⁻¹] | Width[m] |
| DopplerVelocityX[ms ⁻¹] | Height[m] |
| DopplerVelocityY[ms ⁻¹] | Range[m] |
| DopplerVelocityZ[ms ⁻¹] | RangeX[m] |
| Theta[deg] | RangeY[m] |
| Phi[deg] | RangeZ[m] |
| TargetID[-] | DopplerVelocity[ms ⁻¹] |
| TargetTypeID[-] | DopplerVelocityX[ms ⁻¹] |
| EnergyLoss[dB] | DopplerVelocityY[ms ⁻¹] |
| Alpha[deg] | DopplerVelocityZ[ms ⁻¹] |
| Beta[deg] | Theta[deg] |
| - | Phi[deg] |

본 장에서는 시뮬레이터 실험에서 사용될 Lidar, Radar, Vision 센서에 대한 원리 및 기술, 주요 제품의 스펙들을 확인 하였고, 해당 정보와 추가적인 문헌들을 참고하여 시뮬레이터에서의 스펙을 설정하였다. 이러한 스펙을 가진 센서들을 이용하여 추후 4장에서 실험은 시나리오별 각 센서들을 독립적으로 사용하였을 때의 인식오차와 융합하였을 때 오차를 비교한다. 이 때, Lidar, Radar, Vision이 가지고 있는 장점을 유지하고 단점이 보완된 센서 데이터를 융합한 결과를 보여주도록 한다.

제3장 센서데이터 융합을 위한 인공신경망 구축

본 장에서는 앞 장에서 설명하였던 객체인식센서 시스템 구성에 이어서 센서 데이터를 처리하기 위한 인공신경망을 어떻게 구축할 것인지에 대하여 설명한다. 기존 객체인식센서 데이터를 융합하기 위해서는 칼만필터를 사용하여 처리하였지만, 이는 알고리즘의 복잡성이나 환경에 따른 추가적 변수에 의하여 알고리즘의 변화가 많이 필요한 단점이 존재하고 있다. 따라서 인공신경망을 이용하여 센서데이터를 융합함으로써 알고리즘의 복잡성을 낮추고 더불어 환경변수에 의한 알고리즘 변경이 없는 단일화 된 인공신경망을 사용하여 필터의 단점을 해결하려 한다. 제안 시스템 설명을 위하여 먼저 인공신경망의 원리와 본 논문에서 사용할 인공신경망 구축 방법 및 구성을 설명하며 테스트에서 발생할 수 있는 오차를 제거하기 위한 객체인식 오차 보정 알고리즘을 3.3절에서 설명한다.

제3.1절 인공신경망 원리

인공신경망(Neural Network)이란 인간의 뇌가 수많은 뉴런으로 구성된 네트워크로 문제를 처리하는 방식을 컴퓨터에도 적용하여 기계가 스스로 학습할 수 있도록 하는 알고리즘이다. 그림 3.1과 같은 신경세포의 구성을 컴퓨터에 적용할 수 있는 구조로 그림 3.2와 같이 변환한 것이다.




그림 3.1 신경세포의 구성




그림 3.2 인공신경망

인공신경망의 시초는 1943년 미국 일리노이 의대 정신과 부교수였던 워렌 맥컬럭(Warren McCulloch)과 월터 피츠(Walter Pitts)의 <A Logical Calculus of the Ideas Immanent in Nervous Activity>이라는 논문에서 처음 소개 되었다[35]. 그들은 신경세포를 모델링한 뉴런이라는 매우 단순한 기능을 가진 유닛들을 상호 연결하여 AND, OR, NOT과 같은 논리 연산을 수행할 수 있음을 보이고, 뇌의 기능을 이해하기 위한 패턴분류 문제를 신경망의 적용 예로서 제시하였다. 그림 3.3은 신경세포를 모델링한 맥컬럭-피츠 뉴런이다.




그림 3.3 맥클록-피츠 뉴런

신경세포는 수상돌기, 축색돌기, 세포체로 이루어져있다. 수상돌기는 신경이 입력되는 통로, 축색돌기는 신경을 전달하는 역할, 세포체는 입력된 자극이 임

계값 이상이 되면 뉴런을 활성화하여 다른 뉴런에게 자극을 전달한다. 이와 같이 수상돌기를 입력 유닛으로 설정하고, 세포체의 합은 각 유닛과 연결된 연결 가중치를 곱한 합으로 계산된다. 이 때, 임계값을 두기 위한 활성화 함수를 사용한다. 활성화 함수는 일반적으로 그림 3.4와 같은 함수를 사용한다.




그림 3.4 활성화 함수

1949년에는 앞서 연구된 신경망의 연결 강도를 결정하기 위한 방법으로 학습 규칙을 찾으려는 연구로 <행동의 조직(The Organization of Behavior)>이라는 책에서 헤브의 규칙(Hebbian Learning)이라는 규칙을 헤브(Hebb)가 제안한다[36]. 헤브의 규칙은 “만일 어떤 신경세포의 활성화가 다른 신경세포가 활성화하는 데 계속적으로 공헌 한다면, 두 신경세포 간의 연결 가중치를 증가해야 한다,” 라는 가설로 만들어진 규칙이다. 이것이 신경회로망 학습에 관한 연구를 촉진시키는 계기를 만들게 된다.

헤브의 학습규칙을 기초로 하여 컴퓨터 과학자 프랑크 로젠블라트(Frank Rosenblatt)는 1958년 퍼셉트론의 개념을 소개 한다[37]. 퍼셉트론은 신경세포와 유사한 단순 계산 기능을 갖는 요소로 구성된 입력층과 출력층을 갖는 신경 시스템의 모델명이다. 여기서는 델타 규칙(delta rule)을 사용한다. 기본적으로 헤브의 규칙과 유사하지만 신경세포의 활성화값과 목표패턴과의 차이로 잘

못된 출력은 판단하는 기준인 오차가 추가 된다. 퍼셉트론은 기존의 컴퓨터 알고리즘으로는 해결하기 어려웠던 문제를 효율적으로 접근할 수 있다는 것을 보여주었으나, 퍼셉트론은 선형분이 불가능 문제를 해결할 수 없다는 치명적 단점이 존재 하였다.

2년 뒤인 1960년 미국 스탠포드 대학의 전기공학자 버나드 위드로(Widrow)와 호프(Hoff)는 퍼셉트론 모델의 선형화와 유사한 위드로-호프 모델을 제안 하였다[38]. 위드로-호프 모델은 최소평균자승(Least Mean Square) 알고리즘으로 최근까지도 신호처리 분야에서 매우 유용하게 쓰이고 있는 기본적인 학습 방법이다. LMS 학습 알고리즘 개념은 전체 학습 데이터에 대한 전체 오차를 최소화 하는 방향으로 연결 강도를 갱신하는 방법이다.

1960년대 말 민스키(Minsky)와 페퍼트(Papert)는 퍼셉트론의 한계를 수학적으로 증명하였다[39]. 이후 신경망은 암흑기를 맞이하였고, 1970년대에 거의 포기 되었다.

하지만 많은 학자들이 연구를 지속해 온 덕분에 1980년대 MLP(Multi-Layer Perceptron)을 발표하면서 퍼셉트론의 한계를 해결한다. 퍼셉트론은 패턴인식에서 해결해야 할 대부분의 비선형 입력 패턴을 선형 분리하지 못하였지만 MLP를 통하여 복잡한 영역을 곡면으로 둘러싸는 결정 영역을 구할 수 있게 되었다. 층의 구조에 따른 결정 경계를 차이는 그림 3.5에서 확인 할 수 있다[40].

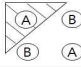
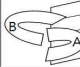

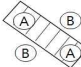
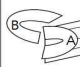

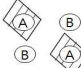


| 구 조 | 결정 구역 | XOR 문제 | 맞물린 영역 모양 | 전형적인 영역 모양 |
|-------|-----------------------------|---|---|--|
| 1층 구조 | 초평면에 의한 평면 경계 |  |  |  |
| 2층 구조 | 열린 블록 혹은 닫힌 블록 경계 |  |  |  |
| 3층 구조 | 임의의 결정 경계 (노드의 수에 따라 모양 결정) |  |  |  |

그림 3.5 신경망 층에 따른 결정 영역

Single-layer일 때는 평면 경계만 가질 수 있지만 Two-layer에서는 열린 블록 또는 닫힌 블록의 경계를 가질 수 있게 된다. Three-layer에서는 노드의 수에 따라 모양을 결정하여 경계를 가질 수 있다.

1980년대 후반 룸멜하트(Rumelhart)와 힌톤(Hinton)은 다층 퍼셉트론에 대한 효율적 학습 방법인 역전파 알고리즘(Back-Propagation)을 개발하였다[41, 42]. 역전파 알고리즘의 구조는 그림 3.6과 같다.




그림 3.6 역전파 알고리즘 구조

역전파 알고리즘 학습은 전향 단계와 후향 단계로 이루어진다. 연결 강도의 갱신은 후향 단계에서 이루어지게 된다. 전향 단계에서는 입력 패턴을 제시하고, 각 노드에 대하여 입력 함수, 활성화 함수를 이용하여 출력은 산출하는 단계이다. 이 때에는 초기 임의의 연결 강도로 인하여 출력값과 목표값의 큰 차이가 발생하게 된다. 후향 단계는 목표값과 출력값에 대한 오차를 구하고 이를 역방향으로 연결 강도를 갱신하는 단계이다. 이 과정을 반복하여 오차의 기준치에 도달할 때까지 원하는 값에 수렴시키는 것이다.

제3.2절 제안 시스템에서의 신경망 구성 방법

먼저 시스템에서 최적의 네트워크를 찾기 위해서는 테스트를 통하여 본 실험에 알맞은 Layer와 Layer에 따른 node를 찾아야 한다. 그림 3.5에서 설명하였듯이 Layer층이 많아진다는 것은 연결 강도의 차원이 늘어난다는 의미이고, 각 Layer의 node수가 많아진다는 것은 입출력 관계를 조금 더 상세하게 표현한다는 의미이다. 하지만 각 사용 분야와 어떤 데이터를 Input으로 넣느냐에 따라 항상 많은 차원의 Layer와 node를 사용한다고 좋아지지 않게 된다. Layer는 보통 2~3개층을 많이 사용하는 편이다. 하지만 Layer와 node 개수는 사용자가 반복 실험을 통하여 얻는 것이 보통이다. 저자는 상대 차량 속도 30km/s로 직진 50m 구간을 주행시키면서 네트워크 Layer, node 수를 변경하며 평가하였다.

표 3.1 Neural Network Layer수와 node수에 따른 RMS 비교

| Network (Layer, node) | RMS |
|-----------------------|---------------|
| [12 6] | 0.2508 |
| [10 8 4] | 0.2523 |
| [12 10 4] | 0.2280 |
| [12 10 6] | 0.2435 |
| [12 8 4] | 0.2020 |

표 3.1에서 나타나있듯이 Layer는 3개층, node수는 각각 12개, 8개, 4개를 사용하였을 시 가장 작은 RMS를 갖기 때문에 본 실험에서는 그림 3.7과 같이 다음 네트워크를 사용하도록 한다.


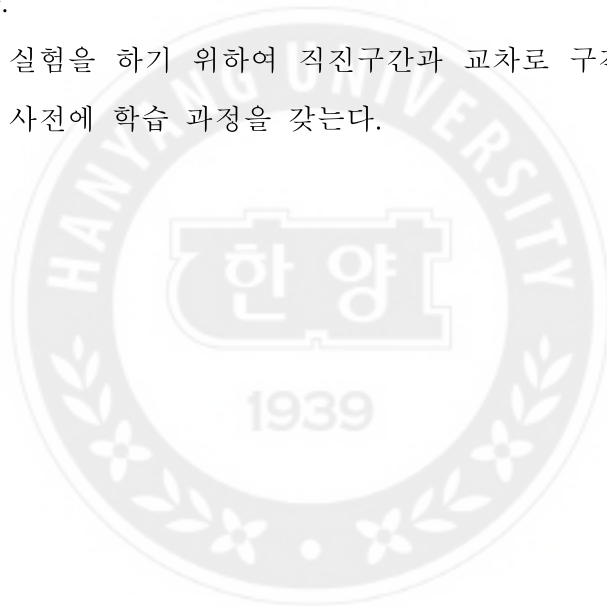



그림 3.7 실험에 사용할 Neural Network 알고리즘


또한, 실험에 앞서 인공신경망의 경우에는 실험 전 도로 상황에 대한 학습 과정이 필요하다.

추후 4장에서 실험을 하기 위하여 직진구간과 교차로 구간에서 각각 다음 그림 3.8과 같이 사전에 학습 과정을 갖는다.





(a) 직진구간 Training 과정




(b) 교차로 구간 Training 과정


그림 3.8 각 구간에서의 Training 과정

그림 3.8은 실험을 진행하기 전 다양한 도로 주행을 학습하는 과정이다. 그림 3.8(a)의 직진구간에서는 1차선, 2차선에서 직진 주행하는 과정과 1차선에서 2차선으로 차선을 변경하거나 반대로 2차선에서 1차선으로 차선을 변경하는 경우, 또 차선을 두 번 변경하는 경우 등을 학습한다. 인공신경망은 많은 학습이 이루어질수록 테스트에서 더 낮은 RMS를 가질 수 있게 되어 많은 학습을 하는 것이 좋다. 그리고 그림 3.8(b)의 교차로 구간에서는 자차와 동일 주행 구간에서 좌회전, 우회전 하는 과정과 직진 주행하는 과정, 자차와 반대편 주행 구간에서 우회전, 좌회전, 직진 등 직진구간보다 더 다양한 과정을 학습하였다. 위 그림은 설명하기 위한 예시로 모든 학습과정을 담지 않았다. 시뮬레이션과 추후에 실차 테스트 때 모두 많은 학습을 하는 것이 좋은데 그 이유 중 하나는 똑같은 직진이라고 하여도 흔들림 없이 정확히 직진할 수 없고, 특히 좌회전, 우회전 할 때에는 커브를 크게 돌거나 작게 도는 경우 등 다양한 상황이 발생하므로 같은 주행 상황도 여러 번 학습하는 것이 테스트에 도움이 될 것이다.

학습의 중요성을 확인하기 위하여 학습 데이터가 다른 경우를 두고 객체가 2차선에서 1차선으로 변경하는 주행 상황을 학습 데이터 개수에 따라 그림 3.9와 같이 비교하였다.



(a) Training data가 324개 일 때 차선 변경 실험



(b) Training data가 564개 일 때 차선 변경 실험

그림 3.9 Training data 개수에 따른 RMS 비교

그림 3.9에서 확인할 수 있듯이 동일한 테스트 구간에서 동일한 네트워크를 사용하고 학습 데이터가 증가 하였을 때, RMS가 0.313838에서 0.073193까지 많이 낮아지는 것을 확인할 수 있다. 따라서 동일한 주행 구간에서도 사전 학습을 여러번 시킬 필요성이 있다는 것을 보였다. 하지만 많은 학습을 하면 성능이 좋아지나 실험 장비 성능의 한계에 따라 제한적이기 때문에 실제로는 고성능의 장비로 실험하지 않으면 한계가 존재한다. 본 실험에서도 학습 데이터 개수에 따른 차이를 보여주는 것 이외에는 장비 성능의 한계로 인하여 최대의 데이터로 실험을 하지는 못하였다.

제3.3절 객체인식 오차 보정 알고리즘

실험 과정에서 발생하는 에러 중 차량 Heading이 변하면서 발생하는 에러 (ex) 좌회전, 우회전 등)나 자차로부터 거리가 멀어지면서 발생하는 오차를 제외하고 차량 Heading이 변하지 않지만 갑자기 튀는 부분이 생겼을 때 이는 확실한 False Value로 인지할 수 있다. 따라서 그러한 값들을 제거해 주면서 전체적인 RMS를 감소시키기 위한 필터를 다음 그림 3.10과 같이 구성하였다.

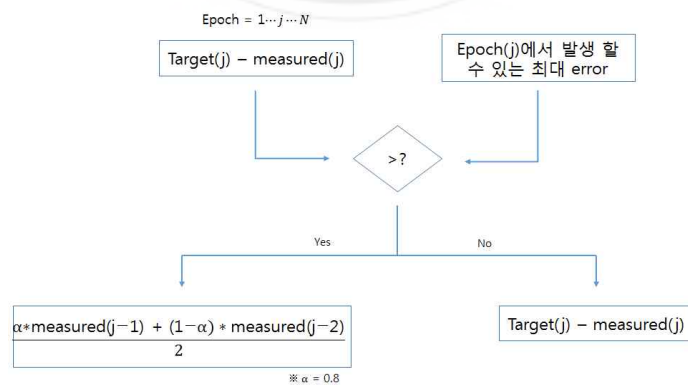


그림 3.10 객체인식 오차 보정 알고리즘

위 그림에서 나타나있듯이 구성은 먼저 목표 값과 측정된 값의 차이, 즉 오차를 구하고 센서 스펙에 따라 Range, Theta의 해당 시간에서 발생할 수 있는 최대 에러를 계산하고 그 이상으로 튀는 부분들은 False 값으로 인지하여 바로 이전 Epoch와 두 번째 이전 Epoch에 해당하는 값의 평균으로 삼는다. 하지만 두 값의 평균을 구할 때 바로 이전 값의 Wight를 높이면서 현재의 False 값을 수정한다. 만약 해당 Epoch에서 발생할 수 있는 최대 에러보다 작다면 그 값은 그대로 사용하도록 구성하였다.

본 장에서는 시뮬레이터 실험에서 사용될 인공지능망의 원리와 구성에 대하여 설명하였고, 실험 결과 값의 정확도를 높이기 위한 객체인식 오차 보정 알고리즘에 대하여 설명하였다. 앞서 설명하였듯이 객체인식 센서 데이터 융합을 위하여 기존에 사용하였던 칼만 필터는 알고리즘이 복잡하고 환경에 따라 달라지는 단점을 가지지만 인공지능망을 적용함으로써 3.2절에서와 같이 최적의 네트워크를 찾아 알고리즘을 단일화 하였다. 이를 이용하여 4장에서는 각각 다른 시나리오에서도 본 장에서 찾은 최적화된 네트워크를 이용하여 실험하고 각 센서를 단일로 사용하였을 때와 융합하였을 때를 비교하도록 한다.

제4장 실험 및 결과

제 4장에서는 앞서 소개한 센서 시스템 구성과 구축된 인공신경망을 기반으로 일반적인 주행환경에서 발생하는 상황에 따른 객체인식 결과 값을 보여준다. 실험을 통하여 2장에서 설명한 객체인식센서를 융합하였을 때 각 센서를 단일로 사용하였을 시 가지는 단점을 보완할 수 있는지에 대하여 확인한다. 또한 3장에서 찾은 최적화된 네트워크를 여러 다른 시나리오에 적용함으로써 동일하게 우수한 성능을 가질 수 있는지에 대하여 확인한다.

제4.1절 실험 환경

본 실험에서는 시뮬레이션을 위하여 PreScan을 사용하였고 인공 신경망을 적용하기 위하여 Matlab을 사용하였다. 실험 전 사용하게 될 차량은 전방에 2D Lidar 1대, LRR(Long Range Radar) 1대, 양 측방에 MRR(Middle Range Radar) 1대씩 총 2대 그리고 차량 앞 유리 부근에 Vision 1대로 총 5개의 센서로 구성되어있다. 센서 스펙은 앞서 2장에서 설명한 것과 동일하게 설정되었다. 시나리오에 따라 각 센서의 개별적인 데이터들은 상황에 따라 가장 최적화된 네트워크를 구성하여 처리하였고, 센서 데이터의 융합에서는 3장에서 설명한 최적화된 인공신경망 네트워크를 사용하여 처리하였다. 시나리오마다 각 센서 데이터 처리를 위한 최적의 네트워크는 각 절에서 표로 제시하였다. 또한 실험은 센서 마다 각각 다른 인지 거리와 다른 FOV를 가지고 있기 때문에 해당 시나리오에서 가장 낮은 인지 거리와 FOV를 가진 센서에 맞는 Epoch만큼의 데이터를 측정하였다.

제4.2절 실험 시나리오


본 절은 연구 방법을 평가하기 위한 다양한 시나리오 환경에 대하여 설명한다. 시나리오는 일반적 주행 상황에서 간주한다. 왕복 4차선의 도로에서 실험하였고, 직진구간과 교차로 상황을 나누어 실험하였다. 자차는 1차선에 고정시켰으며, 먼저 직진구간에서는 객체 차량이 2차선에서 직진하였을 때와 2차선에서 1차선으로 차선을 변경하였을 때에 대하여 각 센서 RMS와 융합하였을 때 RMS를 비교하였다. 직진구간에서는 직진하였을 때와 차선을 변경하였을 때 어떠한 RMS를 갖고 어떠한 시점에서 오차가 크게 발생하는지 분석할 것이다. 또한 교차로 구간에서 객체는 1차선에서 북쪽 방향으로 좌회전 하는 시나리오와 반대 2차선에서 우회전 하는 구간을 시나리오로 두었다. 교차로 구간에서는 좌회전, 우회전뿐만 아니라 반대 차선에서 자차 방향으로 다가오는 시나리오도 실험하기 위하여 우회전을 자차와 동일 방향의 2차선에서가 아니라 반대 차선 2차선에서 북쪽으로 올라가는 방향으로 선택하였다. 모든 실험에서 객체는 30km/s 속도로 진행하였다. 세부적 시나리오는 그림 4.1에 나타나있다.




(a) 직진구간 직진실험



(b) 직진구간 차선변경



(c) 교차로구간 반대차선 우회전



(d) 교차로구간 좌회전

그림 4.1 실험 시나리오

제4.3절 실험 결과 및 분석

실험 결과는 다음과 같이 분석한다. 각 시나리오에서 Lidar, Radar, Vision 만을 각각 사용하여 RMS를 계산한 값과 센서를 융합하여 얻은 RMS를 비교한다. 시나리오에 따른 에러 그래프를 비교하면서 먼저 각 센서를 개별적으로 사용하였을 때와 융합하였을 때를 비교하면서 객체인식센서 데이터 융합이 각 개별센서의 단점을 보완할 수 있는지에 대하여 확인하고 분석하며, 센서 데이터 융합에 사전에 최적화된 네트워크를 사용하면서 필터에서 가지는 알고리즘의 복잡성과 다양성을 해결하고 단일화 될 수 있는지에 대하여도 비교 분석한다.


4.3.1 직진구간 직진실험

첫 번째 실험은 직진구간에서 객체가 직진하였을 때를 실험하였다. 아래 표 4.1에는 직진구간 직진실험에서의 단일 센서, 융합하였을 때 최적의 네트워크 층과 노드 수를 나타내고 있다. 아래 그림 4.2는 실험 시나리오 그림 4.1(a)에서 직진실험은 하고 그를 각 센서 개별에 대한 오차와 융합하였을 때 오차 그래프를 나타낸 것이다. 실험 중 직진실험 같은 경우 객체의 Heading 변화가 보통 크게 일어나지 않고 실제 주행 중에서도 차선 변경할 때 이외에는 직진 주행만을 하기 때문에 에러가 적게 발생한다. 그림 4.2 (a)는 Lidar 개별 센서 데이터를 Layer 3개 층으로 각각 4개씩의 노드를 가진 네트워크로 처리하였다. 그림 4.2 (b)는 Radar 센서 데이터를 2개의 Layer층에 각각 4개, 2개의 노드를 가진 네트워크를 사용하여 오차를 측정하였고, 그림 4.2 (c)는 Vision 센서 데이터를 2개의 Layer층에 각각 6개, 4개의 노드를 가진 네트워크로 오차


를 측정하였다. 그리고 그림 4.2 (d)는 3장에서 찾은 최적의 네트워크인 3개의 Layer층에 각각 12, 8, 4개씩의 노드를 가진 네트워크로 실험하였다. 그림 4.2 (a),(b),(d)는 전체적으로 오차가 적게 발생하는 것을 확인 할 수 있다. 하지만 (c) 같은 경우 뒤로 갈수록 오차가 매우 커지는 것을 볼 수 있는데 이는 비전이 거리에 따라 종방향 오차를 매우 크게 가지게 되는 특성 때문이다. 다른 센서 데이터 값과 달리 목표 값과 출력 값 차이가 최대 약 15.5m 까지 나게 된다. 하지만 다른 두 센서들은 직진 상황에서 Lidar는 0.4815m, Rdar는 0.6066m의 RMS로 모두 전체적으로 작은 오차들을 보여주고, Fusion을 하였을 시, 오차가 가장 낮은 Lidar보다도 약 0.28m정도 낮은 0.2020m의 RMS를 갖는다. 본 실험의 그래프를 비교해보면 센서 데이터 융합 시 가장 좋은 성능을 내며, 그 이유는 앞서 2장에서 설명한 각 센서가 가진 거리 인식의 한계와 FOV의 한계를 보완하였기 때문이다.

표 4.1 직진 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크


| Sensor | Layer 개수 | node 개수 |
|--------|----------|----------|
| Lidar | 3 | 4, 4, 4 |
| Radar | 2 | 4, 2 |
| Vision | 2 | 6, 4 |
| Fusion | 3 | 12, 8, 4 |




(a) 직진구간 직진주행 시 Lidar error 그래프



(b) 직진구간 직진주행 시 Radar error 그래프



(c) 직진구간 직진주행 시 Vision error 그래프



(d) 직진구간 직진주행 시 Fusion error 그래프

그림 4.2 직진구간 직진주행 시 각 센서 및 Fusion error 비교


4.3.2 직진구간 차선변경 실험


두 번째로 직진구간에서 차선변경 실험을 하였다. 아래 표 4.2에는 직진구간 차선변경 실험에서의 단일 센서, 융합하였을 때 최적의 네트워크 층과 노드 수를 나타내고 있다. 아래 그림 4.3는 실험 시나리오 그림 4.1(b)에서 차선변경 실험은 하고 그를 각 센서 개별에 대한 오차와 융합하였을 때 오차 그래프를 나타낸 것이다. 직진주행만을 할 때 보다 Heading의 큰 변화가 생기는 차선변경 시점에서 오차가 발생하는 것을 확인 할 수 있다. 그림 4.3을 보게 되면 Epoch 22에서 31 사이에서 크게 한번 씩 튀는 모습을 확인 할 수 있는데 이는 차선이 변경 되는 시점을 의미한다. 그림 4.3 (a)는 Lidar 개별 센서 데이터를 Layer 2개 층으로 각각 6, 4개씩의 노드를 가진 네트워크로 처리하였다. 그림 4.3 (b)는 Radar 개별 센서 데이터를 Layer 2개 층으로 각각 4개씩의 노드를 가진 네트워크로 처리하였다. 또한, 그림 4.3 (c)는 Vision 개별 센서 데이터를 Layer 3개 층으로 각각 8, 4, 4개씩의 노드를 가진 네트워크로 처리하였고, 그림 4.3 (d)는 3장에서 찾은 최적의 네트워크인 3개의 Layer층에 각각 12, 8, 4개씩의 노드를 가진 네트워크로 실험하였다. 그림 4.2 (c)와 비슷하게 그림 4.3 (c) Vision 센서는 거리에 따라 큰 오차를 가지는 것을 확인 할 수 있다. 그림 4.3 (a) Lidar에서는 최대 오차가 1.8m 까지 발생하지만 다른 부분에서는 전체적으로 낮은 0.4932m의 RMS 값을 갖고, 그림 4.3 (b) Radar는 Lidar와 비슷한 형태의 그래프를 그리지만 차선을 변경하는 구간 이외에도 상대적으로 오차가 높은 0.6379m의 RMS를 갖는 것을 확인 할 수 있다. 마지막으로 그림 4.3 (d)를 보면 역시 최소 차이 값을 갖는 Lidar보다 낮은 차이를 보여 줌을 확인 할 수 있고 차선이 변경되는 지점 이외에는 매우 낮은 차이 값을 가지면서 0.3138m의 RMS를 보여 주었다. 앞서 4.3.1 직진구간 직진실험에서보다 전체적으로 다소 높은 RMS를 보였는데 그 이유는 차선의 변경되는

시점에서 순간적인 오차가 크게 발생하기 때문이다. 하지만 그림 4.3 (d)를 보면 최대오차 뿐만 아니라 전체적인 오차를 더 낮추면서 센서 데이터를 융합함으로써 더 좋은 성능을 보일 수 있음을 확인하였다.


표 4.2 차선 변경 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크

| Sensor | Layer 개수 | node 개수 |
|--------|----------|----------|
| Lidar | 2 | 6, 4 |
| Radar | 2 | 4, 4 |
| Vision | 3 | 8, 4, 4 |
| Fusion | 3 | 12, 8, 4 |







(a) 직진구간 차선 변경 시 Lidar error 그래프



(b) 직진구간 차선 변경 시 Radar error 그래프



(c) 직진구간 차선 변경 시 Vision error 그래프



(d) 직진구간 차선 변경 시 Fusion error 그래프

그림 4.3 직진구간 차선 변경 시 각 센서 및 Fusion error 비교


4.3.3 교차로 반대 차선 우회전 실험

세 번째 실험은 그림 4.1 (c) 시나리오 실험으로 반대 방향에서 다가오는 차량상태와 우회전 할 때 상태를 모두 고려하기 위한 실험으로 각 센서 개별에 대한 오차와 융합하였을 때 오차 그래프를 나타낸 것이다. 아래 표 4.3에는 교차로에서 반대 차선 우회전 실험에서의 단일 센서, 융합하였을 때 최적의 네트워크 층과 노드 수를 나타내고 있다. Epoch 34에서 41까지 우회전을 하는 시점이다. 먼저 그림 4.4 (a)는 Lidar 개별 센서 데이터를 Layer 3개 층으로 각각 4개씩의 노드를 가진 네트워크로 처리하였다. 그림 4.4 (b)는 Radar 개별 센서 데이터를 Layer 3개 층으로 각각 6, 4, 2개씩의 노드를 가진 네트워크로 처리하였다. 또한, 그림 4.4 (c)는 Lidar 개별 센서 데이터를 Layer 2개 층으로 각각 6, 4개씩의 노드를 가진 네트워크로 처리하였다. 마지막으로 그림 4.4 (d)는 3장에서 찾은 최적의 네트워크인 3개의 Layer층에 각각 12, 8, 4개씩의 노드를 가진 네트워크로 실험하였다. 먼저 그림 4.4 (a) Lidar를 보면 우회전을 하는 시점에서 오차가 잠시 크게 발생한다. 이외에는 다시 낮게 발생하는 그래프를 그리며 RMS 0.4500m의 값을 갖는다. 그림 4.4 (b) Radar 또한 Lidar와 흡사한 그래프를 그리나 앞 실험과 같이 우회전 시점에서 더 큰 오차를 보이며 RMS가 0.7750m으로 조금 높게 갖게 된다. 그림 4.4 (c) Vision에서는 오차가 초반에 크다가 작아지는 그래프를 볼 수 있는데 이는 반대 차선에서 객체가 다가올 시 처음 있던 객체의 거리가 자차로부터 가장 멀기 때문에 더 큰 오차를 갖다가 가까워지면서 오히려 오차가 낮아짐을 확인 할 수 있다. 하지만 1.7393m의 RMS로 다른 센서에 비하여 큰 RMS를 갖는 것은 같다. 마지막으로 그림 4.4 (d)에서 Fusion 하였을 때를 보면 Lidar와 거의 유사한 그래프를 보인다. 최대 오차가 조금 차이가 나는 것 이외에 형태가 비슷하나 전체적으로 더 낮은 오차를 가지면서 0.3851m의 RMS를 갖는다. 본 실험에서는 전


체적으로 앞선 차선변경 실험보다 조금 높은 RMS를 갖는 것을 확인할 수 있는데 이는 차선변경 하는 시점 보다 우회전 하면서 더 긴 시간동안 heading이 변화하기 때문이다. 그림 4.4 (d)를 보면 타 센서들이 갖는 RMS 보다는 작으나 앞선 실험보다는 조금 큰 RMS를 갖는 것을 확인할 수 있다.

표 4.3 교차로 우회전 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크


| Sensor | Layer 개수 | node 개수 |
|--------|----------|----------|
| Lidar | 3 | 4, 4, 4 |
| Radar | 3 | 6, 4, 2 |
| Vision | 2 | 6, 4 |
| Fusion | 3 | 12, 8, 4 |




(a) 교차로 반대 차선 우회전 시 Lidar error 그래프



(b) 교차로 반대 차선 우회전 시 Radar error 그래프



(c) 교차로 반대 차선 우회전 시 Vision error 그래프



(d) 교차로 반대 차선 우회전 시 Fusion error 그래프

그림 4.4 교차로 반대 차선 우회전 시 각 센서 및 Fusion error 비교

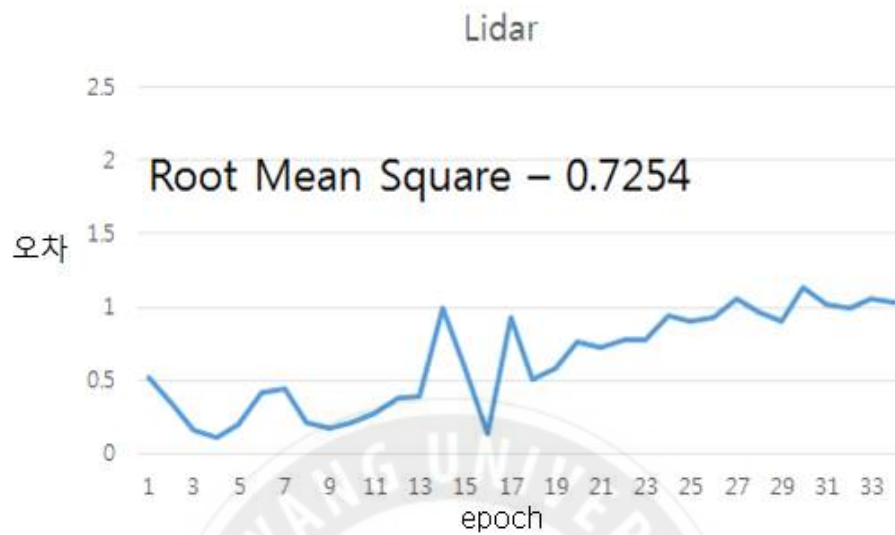
4.3.4 교차로 좌회전 실험

마지막 실험은 그림 4.1 (d)로 자차와 같은 차선에서 북쪽 방향으로 좌회전 하는 시나리오로 각 센서 개별에 대한 오차와 융합하였을 때 오차 그래프를 나타낸 것이다. 아래 표 4.4에는 교차로에서 좌회전 실험에서의 단일 센서, 융합하였을 때 최적의 네트워크 층과 노드 수를 나타내고 있다. 그림 4.5 (a)는 Lidar 개별 센서 데이터를 Layer 3개 층으로 각각 6, 4, 4개씩의 노드를 가진 네트워크로 처리하였다. 그림 4.5 (b)는 Radar 센서 데이터를 Layer 2개 층으로 각각 10, 8, 4개씩의 노드를 가진 네트워크로 오차를 측정하였다. 그림 4.5 (c)는 Vision 센서 데이터를 Layer 2개 층으로 각각 8, 6, 4개씩의 노드를 가진 네트워크로 처리하였으며, 그림 4.5 (d)는 3장에서 찾은 최적의 네트워크인 3개의 Layer층에 각각 12, 8, 4개씩의 노드를 가진 네트워크로 실험하였다. 본 실험에서는 전체적으로 RMS가 조금 증가한 것을 확인 할 수 있고, Epoch 9에서 20까지는 좌회전을 하는 시점이다. 좌회전을 하는 부분에 대해서는 전체적으로 오차가 크게 증가하는 편이다. 그림 4.5 (a) Lidar 같은 경우 우회전에 비하여 RMS가 약 0.3m 이상 증가하였고, 좌회전 하는 시점 또한 오차가 증가하는 것을 확인 할 수 있다. 그림 4.5 (b) Radar는 우회전 때에 비해 RMS가 약간 감소하였지만 좌회전 하는 부분에서는 역시 오차가 증가하여 0.7389m의 RMS를 보였다. 그림 4.5 (c) Vision는 본 실험에서도 자차와의 거리가 증가하면서 오차가 전체적으로 증가하여 0.9850m의 RMS를 보이고 있다. 그림 4.5 (d)의 센서 데이터 융합 부분은 다른 실험에 비하여 큰 0.4006m의 RMS를 가졌지만 각 센서의 RMS 보다 낮은 값을 가짐을 확인할 수 있었다. 다른 시나리오 비하여 좌회전에서 RMS가 전체적으로 높은 이유는 가장 객체가 먼 거리에서 실험이 시작되는 거리상의 이유와 좌회전을 하는 동안 heading변화의 시점이 상대적으로 길기 때문이다.


표 4.4 교차로 좌회전 실험에서 단일 센서별, 센서 융합 시 최적의 네트워크

| Sensor | Layer 개수 | node 개수 |
|--------|----------|----------|
| Lidar | 3 | 6, 4, 4 |
| Radar | 2 | 10, 8, 4 |
| Vision | 2 | 8, 6, 4 |
| Fusion | 3 | 12, 8, 4 |

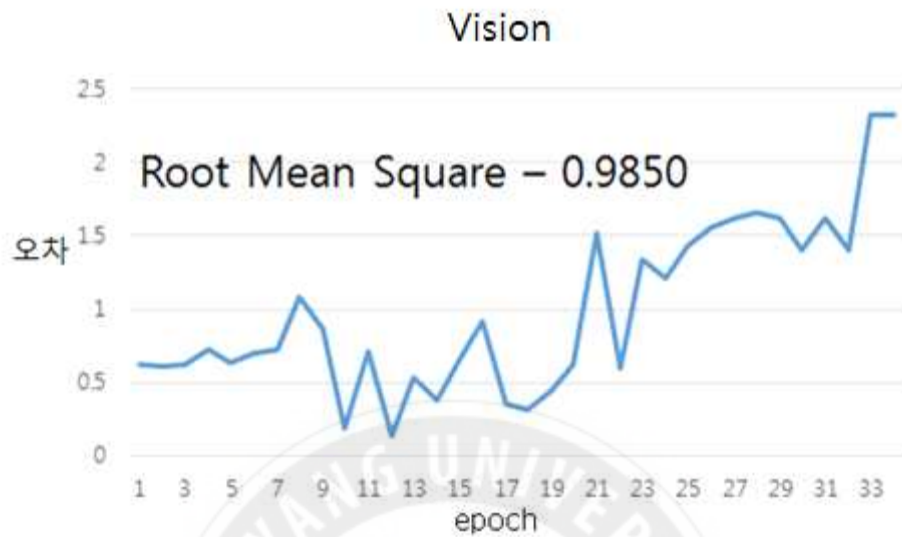




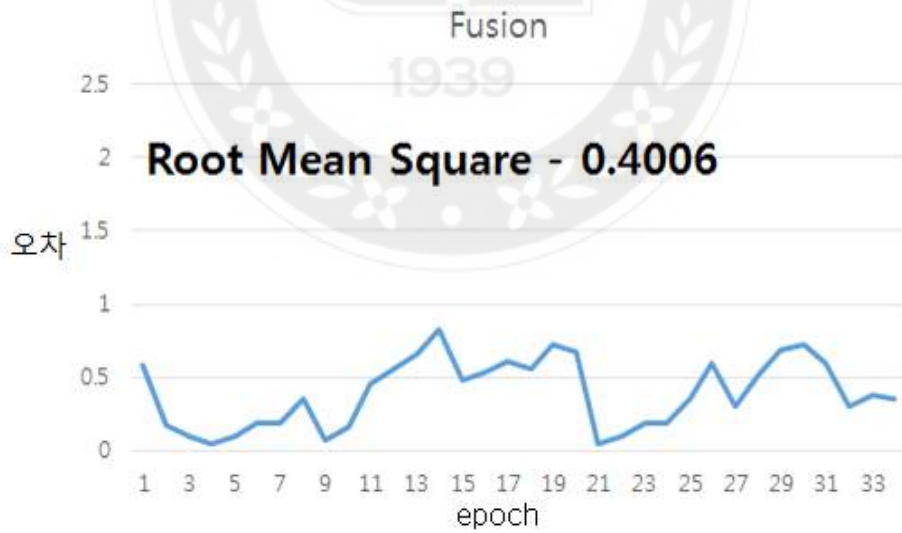
(a) 교차로에서 좌회전 시 Lidar error 그래프



(b) 교차로에서 좌회전 시 Radar error 그래프



(c) 교차로에서 좌회전 시 Vision error 그래프



(d) 교차로에서 좌회전 시 Fusion error 그래프

그림 4.5 교차로 좌회전 시 각 센서 및 Fusion error 비교

제5장 결론

본 논문에서는 일반적인 주행 상황에서 자율주행 센서(Lidar, Radar, Vision) 데이터를 인공지능망을 통하여 융합하는 방법을 제안하였다. 그리고 시나리오에서 각각의 센서를 단일로만 사용하였을 때와 융합하였을 때의 결과를 비교하였다.

센서 별로 결과를 확인하여 보면 시뮬레이션에서는 Lidar나 Radar는 표 2.6에 나타나 있는 규격과 같이 거리에 대한 오차, 방위각에 대한 오차가 거리에 상관없이 랜덤하게 생기는 편이었고, Vision 센서는 거리에 대해 오차를 크게 받을 수 있었다. 4장의 실험 결과에서 각 시나리오마다 각 센서들의 테스트시 각기 다른 네트워크를 구성하였는데 이는 데이터 개수가 조금 달라지거나 조금 다른 오차가 입혀진 데이터를 입력으로 사용할 때 등 일정하지 않고 유동적이며 저자는 반복 실험으로 통하여 제 상황에 맞는 네트워크를 구성하였다

먼저 직진구간에서 차량이 직진주행을 하였을 때, 각 센서를 개별로 사용하였을 때 Lidar는 0.4815m, Radar는 0.6066m, Vision은 2.2120m의 RMS를 나타내었다. Lidar나 Radar의 경우 직진주행에서는 전체적으로 낮은 오차를 갖는 모습을 확인 하였고, Vision의 경우 직진 주행이지만 거리가 멀어지면서 발생하는 오차가 매우 크게 나타남을 알 수 있었다. 그리고 센서 데이터를 융합하였을 시, 0.2020m의 가장 낮은 RMS로 개별 센서에서 가장 낮은 RMS를 갖는 Lidar보다 좋은 성능을 나타내는 것을 확인 할 수 있었다.

다음으로 직진구간에서 차선변경이 있는 경우에는 전체적으로 앞서 직진 주행보다 큰 RMS를 갖는 것을 확인 할 수 있었으며, Lidar의 경우에는 0.4932m, Radar는 0.6379m, Vision은 2.7435m의 RMS를 나타내었다. 3개의 센

서 모두 차선이 변경하는 곳에서 순간적으로 큰 오차가 발생하였다. 센서 데이터를 융합한 경우에도 0.3138m 로 가장 낮은 RMS를 보였지만 직진주행보다는 조금 높은 RMS를 갖는 것을 확인하였다.

세 번째 우회전 실험에서는 Lidar, Radar, Vision 각각 0.4500m, 0.7750m, 1.7393m의 RMS를 보였고, 데이터 융합 시에는 0.3851m로 차선변경 실험보다 조금 높은 RMS를 확인 할 수 있었다. 그 이유는 차선변경 시간보다 긴 시간 우회전을 하기 때문이다.

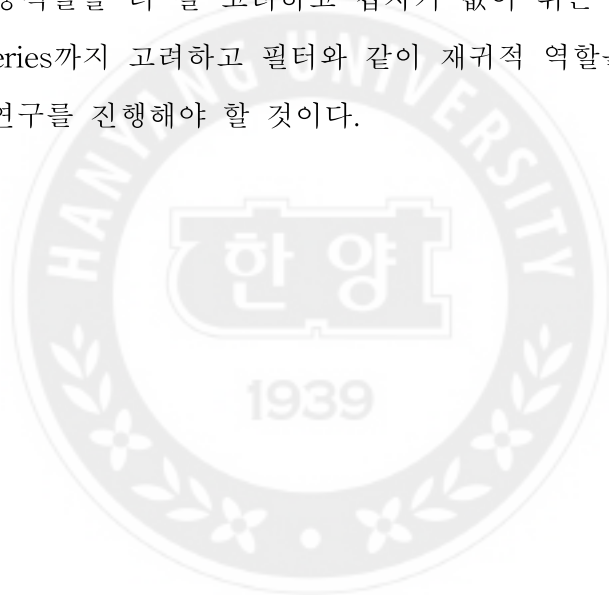
마지막으로 좌회전 실험에서는 Lidar, Radar, Vision 각각 0.7254m, 0.7389m, 0.9850m로 앞 실험 보다 가장 큰 RMS를 갖는 것을 확인할 수 있는데 이는 가장 긴 시간동안 진행 방향이 변화하면서 센서에 의해 차량의 검지되는 부분이 계속 변하면서 생기는 오차이다. 그러나 Lidar, Radar와 달리 Vision은 직진에서보다 우회전, 좌회전에서 RMS가 감소하였는데 이는 직진주행보다 거리가 적게 멀어지기 때문에 작은 오차가 발생한 것이다. 이때 센서 데이터를 융합한 결과는 다른 센서에 비하여 0.4006m로 가장 낮은 RMS를 갖지만 타 실험에 비해 가장 높은 RMS가 나타난 것을 확인 할 수 있었다.

실험 결과를 보면 직진하였을 때 전체적으로 적은 오차를 가지음 확인하였고 차선 변경, 우회전, 좌회전 등 객체의 진행 방향이 변하는 시점에서 오차가 증가하는 것을 보였다. 이러한 이유로는 전체적인 사전 학습 부족을 가장 큰 이유로 볼 수 있다. 학습은 빅데이터 급으로 많은 양을 학습 시킬 수 없는 현실적인 어려움이 있기 때문에 테스트시 학습이 되지 않은 지점을 지나거나 조금 다른 방향으로 진행 될 때 오차가 발생하는 것을 어느 정도 감수해야 한다.

하지만 본 방법을 사용함으로써 상대거리, 방위각을 이용하여 객체 위치 추정 시 객체의 GPS 지점으로 기준을 맞춰야 하기에 위치 보상을 해줘야 하는 기존 필터의 단점을 해결할 수 있었다. 또한 입력 변수나 환경에 따라 알고리

증을 추가 하여 시스템이 복잡해지거나 할 필요가 없이 단순화 되고 획일화 되었다는 장점을 가지고 있다. 그리고 앞서 2장에서 설명하였듯이 단일 센서를 사용하였을 때에 가지는 인식 거리의 한계, FOV의 한계 등을 센서 융합으로 해결 하여 모든 실험 시나리오에서 보다 나은 성능을 갖는 것을 보였다.

본 논문에서는 센서 데이터를 융합하고 객체의 GPS 위치를 추정하는 과정을 보임으로써 인공신경망의 성능을 증명하였다. 아직은 연구가 미비하여 인공신경망의 가장 간단한 Backpropagation 방법을 사용하였지만 추후에는 차량의 다이내믹한 동작들을 더 잘 고려하고 갑자기 값이 튀는 것을 방지 할 수 있도록 Time Series까지 고려하고 필터와 같이 재귀적 역할을 할 수 있는 방법으로 추가적 연구를 진행해야 할 것이다.



참고 문헌

- [1] 이재관, “자율주행자동차 동향과 전망”, 융합 Weekly TIP, 2015. 08
- [2] 채희근, “자동차 진화의 새물결 (2)”, 현대증권, 2015. 03
- [3] 성낙환, “애플카는 구글카와 다르다”, LG Business Insight 2015, Weekly 포커스, 2015. 04
- [4] 안경환, 이상우, 한우용, 손주찬, “자율주행 자동차 기술 동향”, ETRI, 전자통신동향분석 제 28권 제 4호, 2013. 08
- [5] 주건엽, 한재현, 이민채, 김동철, 조기춘, 오동언, 윤이내, 광명기, 한광진, 이동휘, 최병도, 김양수, 이강운, 허건수, 선우명호, “자율주행 자동차 개발: A1”, KSAE, Vol. 19, No. 4, pp 146-154 2011
- [6] M. Akhlaq, Tarek R. Sheltami, Bo Helgeson, Rlhadi M. Shakshuki, “Designing an integrated driver assistance system using image 센서s”, Springer, J Intell Manuf, 2012
- [7] 이정훈, 김현용, “자동차에 전기가 흐른다”, 이베스트투자증권, 2015. 05
- [8] Abel Mendes, Luis Conde Bento and Urban0 Nunes “Multi-target detection and tracking with laser range finder”, 2004 IEEE Intelligent Vehicles Symposium, 2004. 06
- [9] H. Zhao X.W.Shao K.Katabira R. Shibasaki, “Joint tracking and classification of moving objects at intersection using a single-row laser range scanner”, Proceedings of the IEEE ITSC 2006, 2006. 09
- [10] Z. J. Chong¹, B. Qin¹, T. Bandyopadhyay², M. H. Ang Jr.¹, E. Frazzoli³, D. Rus, “ Synthetic 2D LIDAR for Precise Vehicle Localization in 3D Urban Environment“, 2013 IEEE ICRA, 2014, 05
- [11] Benoît Fortin, Régis Lherbier, and Jean-Charles Noyer, “A Model-Based Joint Detection and Tracking Approach for Multi-Vehicle Tracking With Lidar Sensor”, IEEE, Vol. 16, No 4, 2015. 08

- [12] Alberto Y. Hata and Denis F. Wolf, "Feature Detection for Vehicle Localization in UrbanEnvironments Using a Multilayer LIDAR", IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS, VOL. 17, NO. 2, 2016. 02
- [13] T. Ogawa and G. Wanielik, "Track-Before-Detect Approach on LIDAR Signal Processing for Low SNR Target Detection", 2016 IEEE Intelligent Vehicles Symposium (IV)Gothenburg, 2016. 06
- [14] U. Franke and S. Heinrich, "Fast Obstacle Detection for Urban Traffic Situation", IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS, VOL. 3, NO. 3, 2002. 10
- [15] Yingping Huang, "Obstacle Detection in Urban Traffic Using Stereovision", Proceedings of the 8th International IEEE Conference on Intelligent Transportation Systems, 2005. 10
- [16] Amirali Jazayeri, Hongyuan Cai, Jiang Yu Zheng, Mihran Tuceryan, "Vehicle Detection and Tracking in Car Video Based on Motion Model", IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS, VOL. 12, NO. 2, 2011. 06
- [17] Soo Siang Teoh, Thomas Bräunl, "Performance Evaluation of HOG and Gabor Features for Vision-based Vehicle Detection", 2015 IEEE International Conference on Control System, Computing and Engineering, 2015. 11
- [18] Giancarlo Alessandretti, Alberto Broggi and Pietro Cerri, "Vehicle and Guard Rail Detection Using Radar and Vision Data Fusion", IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS, VOL. 8, NO. 1, MARCH 2007
- [19] Eric Richter, Robin Schubert and Gerd Wanielik, "Radar and Vision based Data Fusion - Advanced Filtering Techniques for a Multi Object Vehicle Tracking System", 2008 IEEE Intelligent Vehicles Symposium Eindhoven University of Technology, 2008. 06
- [20] Fernando Garcia1, Pietro Cerri2, *Member, IEEE*, Alberto Broggi, Escalera1 and José María Armingol, "Data Fusion for Overtaking Vehicle Detection based on Radar and Optical Flow" , 2012 Intelligent Vehicles Symposium, 2012. 06

- [21] Ricardo Omar Chavez-Garcia and Olivier Aycard, "Multiple Sensor Fusion and Classification for Moving Object Detection and Tracking", IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS, VOL. 17, NO. 2, 2016 02
- [22] Akash Agarwal, "Sensor Fusion for Navigation of Autonomous Underwater Vehicle using Kalman Filtering", Department of Electrical Engineering National Institute of Technology Rourkela, 2015
- [23] 박세환, "LIDAR 기술 및 산업동향", Technical Note1, 2013. 07
- [23] 이규택, 이건재, 문역국, "라이다(LiDAR) 기술동향과 산업 전망", KEIT PD Issue Report, Vol 16-05, 2016. 05
- [24] 김종덕, 권기구, 이수인, "라이다 센서 기술동향 및 응용", ETRI, 2012 Electronics and Telecommunications Trends, 2012
- [25] "레이더센서를 이용한 신호제어용 실시간 검지체계 개발", 치안정책 연구소, 2012-2013 책임연구보고서
- [26] 노영환, 박두진, 김태형, "발사체 추적용 도플러 레이더의 기술개발 동향", KARI, 항공우주산업기술동향 11권 2호, 2013
- [27] Kissinger, D., "Millimeter-Wave Receiver Concepts for 77GHz Automotive Radar in Silicon-Germanium Technology", Springer, 2012
- [28] 서재규, 정호기, "Stereo Vision Systems for Automotive Applications", KSAE, 지능형자동차 인식시스템 개발동향, 2014. 08
- [27] Maria S. Greco, "Automotive Radar", 2012 IEEE Radar Conference, 2012. 05
- [29] Alberto Broggi, Paolo Grisleri and PaoloZani, "Sensors Technologies for intelligent vehicles perception systems: a comparison between vision and 3D-LIDAR", Proceedings of the 16th international IEEE Annual Conference on ITSC 2013, 2013. 10
- [30] Maria S. Greco, "Automotive Radar", 2012 IEEE Radar Conference, 2012. 05
- [31] G. Broten and J.Collier, "The Characterization of an Inexpensive Nodding Laser", Technical Report, DRDC Suffield TR 2005-232, 2005. 12

- [32] "LMS511-10100 PRO dataSheet", SICK
- [33] "Scanning Laser Range Finder UTM-30LX/LN Specification", HOKUYO AUTOMATIC CO.,LTD, 2012. 11
- [34] Leo Stanislas, Thierry Peynot, "Characterisation of the Delphi Electronically Scanning Radar for Robotixs Applications", ACRA 2015, 2015. 12
- [35] WARREN S. McCulloch, WALTER PITTS, "A Logical Calculus of The Ideas Immanent in Nervous Activity', Bulletin of Mathematical Biophysics, Volume 5, 1943
- [36] Miller, K. D. & MacKay, D. J. C., "The role of constraints in Hebbian learning", Neural Comput, 1994
- [37] Frank Rosenblatt, "Two theorems of statistical separability in the perceptron", 1958
- [38] Bernard Widrow and Marcian E. Hoff, "Adaptive Switching Circuits", 1960
- [39] P. Greco, J. Grize, S.Papert and J. Piaget, "Problems de la construction funombre, Etudes depistemologie genetique XI", 1960
- [40] AJ Shepherd, "Second-order methods for neural networks: Fast and reliable training methods for multi-layer perceptrons", 2012
- [41] David C. Plaut, Geoffrey E. Hinton, "Learning sets of filters using back-propagation", Computer Speech & Language, Vol 2, Issue 1, 1987. 03
- [42] Y Chauvin, DE Rumelhart, "Backpropagation: theory, architectures, and applications", 1995

ABSTRACT

A Study on Sensor Data Fusion using Neural Networks for Autonomous Driving Applications

BongYoung Woon

Dept. of Electronics and Computer Engineering

The Graduate School

Hanyang University

Currently autonomous vehicles are developing rapidly. It is anticipated to play a very key role in the future, and it focuses on many countries, companies and research institutes. Four factors are essential for autonomous vehicles: Perception, Localization, Path Planning, and Vehicle Control. Among them, various sensors such as Lidar, Radar, Vision, and Ultrasonography are installed in the vehicle to obtain information about the surrounding environment and information about the objects (cars, motorcycles, bicycles, people, etc.) around the vehicle. For autonomous driving, precise recognition of the surrounding environment is necessary to prevent collision and control the vehicle such as acceleration and deceleration.

In this paper, data of Lidar, Radar, and Vision sensors, which are essential among them, are fused through Neural Network. And demonstrates better performance than using a single sensor for each. Previous researches have used Kalman filter to fuse two or more sensors.

However, they have complexity of algorithms, and it is necessary to add variables according to environment. In addition, since the sensor data usually gives a distance to the outside of the relative object, there is a disadvantage that the sensor data must be compensated for obtaining the accurate GPS position. On the other hand, when the artificial neural network is tested through prior learning, it is unnecessary to compensate by unifying the algorithm and setting the target value to the relative object GPS position. In this experiment, the performance was evaluated by comparing the basic conditions such as straightness, left turn, and right turn in a typical driving environment, when each sensor was used separately and when it was fused. First, when the vehicle runs straight in the straight line, when the sensors are used individually, Lidar is 0.4815m, Radar is 0.6066m, and Vision is 2.2120m RMS. In the case of Lidar or Radar, it was confirmed that there is a low error overall in the straight run. In the case of Vision, it is found that the error caused by distance travel is very large. When the sensor data is fused, it shows that the lowest RMS of 0.2020m is better than Lidar which has the lowest RMS in the individual sensor. Next, in the case of lane change in the straight line section, it is confirmed that RMS is larger than that of the straight running ahead. In the case of Lidar, 0.4932m, Radar is 0.6379m and Vision is 2.7435m RMS. In all three sensors, a large error occurred instantaneously where the lane changes. Even when the sensor data were converged, the lowest RMS was obtained at 0.3138 m, but it was confirmed that the RMS was slightly higher than the straight running. In the third right turn experiment, RMS of 0.4500m, 0.7750m, and 1.7393m

were shown for Lidar, Radar, and Vision, and 0.3851m for data fusion, respectively. This is because the vehicle makes a right turn longer than the lane change time. Finally, in the left turn test, Lidar, Radar, and Vision are 0.7254m, 0.7389m, and 0.9850m, respectively, which is the largest RMS than the previous experiment. This is because the heading changes for the longest time, It is an error caused by continuous change. However, unlike Lidar and Radar, Vision has a right turn and a decrease RMS in the left turn, which is a little smaller than the straight run. At this time, the result of fusion of the sensor data is 0.4006 m, which is the lowest RMS of other sensors. Through this experiment, we can see the result of solving the limitation of the distance recognition and the limitation of the FOV that occurs when each sensor data is processed as a single data by data fusion.

연구 윤리 서약서

본인은 한양대학교 대학원생으로서 이 학위논문 작성 과정에서 다음과 같이 연구 윤리의 기본 원칙을 준수하였음을 서약합니다.

첫째, 지도교수의 지도를 받아 정직하고 엄정한 연구를 수행하여 학위논문을 작성한다.

둘째, 논문 작성시 위조, 변조, 표절 등 학문적 진실성을 훼손하는 어떤 연구 부정행위도 하지 않는다.

셋째, 논문 작성시 논문유사도 검증시스템 "카피킬러"등을 거쳐야 한다.

학위명 : 석사

학과 : 전자컴퓨터통신공학과

지도교수 : 이상선

성명 : 윤봉영



한 양 대 학 교 대 학 원 장 귀 하

Declaration of Ethical Conduct in Research

I, as a graduate student of Hanyang University, hereby declare that I have abided by the following Code of Research Ethics while writing this dissertation thesis, during my degree program.

"First, I have strived to be honest in my conduct, to produce valid and reliable research conforming with the guidance of my thesis supervisor, and I affirm that my thesis contains honest, fair and reasonable conclusions based on my own careful research under the guidance of my thesis supervisor.

Second, I have not committed any acts that may discredit or damage the credibility of my research. These include, but are not limited to : falsification, distortion of research findings or plagiarism,

Third, I need to go through with Copykiller Program(Internet-based Plagiarism-prevention service) before submitting a thesis."

DECEMBER 08, 2016

Degree : Master

Department : DEPARTMENT OF ELECTRONICS AND COMPUTER ENGINEERING

Thesis Supervisor : Lee Sang Sun

Name : WOOD BONG YOUNG

(Signature)